

基于时空聚类与非齐次生灭过程的 共享单车潮汐调度模型 ——以上海市真实订单数据为例

肖彦松

学号：523120910119

安泰经济与管理学院

2026 年 6 月

摘要

共享单车系统中的“潮汐现象”——早晚高峰期间车辆在住宅区与商务区之间的单向大规模流动——是导致系统运营效率下降的核心挑战。本文利用 2016 年 8 月上海市摩拜单车全量订单数据，通过 K-Means 空间聚类自动识别出一对镜像互补的潮汐站点（净流入 CBD 站与净流出住宅站），并对数据时间精度进行严格诊断，进而采用小时级计数泊松检验确认非齐次泊松过程（NHPP）建模的必要性。在此基础上，分别为两个站点构建 $M(t)/M(t)/1/K$ 变参数生灭过程模型，通过 Kolmogorov 前向方程数值求解与 Gillespie 算法仿真获得单车数量的瞬态概率分布。基于瞬态风险分析，本文提出动态 $(s(t), S(t))$ 调度阈值策略并进行经济学成本优化。核心发现表明：传统卡车物理调度因单次成本高昂而呈现显著的边际收益递减——全局净收益近乎为零；相比之下，扩大基础设施容量（画线扩容）与基于边际成本替代的逆向红包补贴（以卡车调度边际成本为补贴上限）具有压倒性的经济学优越性。本文从运筹学视角为共享单车系统的轻资产运营提供了定量决策依据。

关键词：共享单车；潮汐现象；非齐次生灭过程；Gillespie 算法；时空聚类；分散检验；动态调度；边际成本替代；逆向补贴

1 引言与文献综述

1.1 研究背景

共享单车作为解决城市“最后一公里”出行需求的重要基础设施，自 2016 年起在中国各大城市迅速普及。然而，系统的运营效率受到一个核心问题的制约——潮汐现象（Tidal Phenomenon）：在早高峰时段，大量用户从住宅区骑行至地铁站或 CBD 区域，

导致住宅区车辆枯竭（空站）而商务区车辆堆积（满站）；晚高峰则呈现反向流动。这种微观层面的市场失灵，使得单纯依赖用户自发调节无法实现系统的供需平衡。

从随机过程的视角审视，潮汐现象的本质是**到达率的时间非齐次性**：借车需求率 $\lambda(t)$ 和还车供给率 $\mu(t)$ 不仅随时间剧烈变化，而且在空间上呈现系统性差异——住宅区的 $\lambda(t)$ 在早高峰远超 $\mu(t)$ （净流出），而 CBD 区域的 $\mu(t)$ 在早高峰远超 $\lambda(t)$ （净流入）。这种时空耦合的非齐次性，使得传统的齐次排队模型无法准确刻画系统的动态行为。

上海市作为中国共享单车发展最成熟的城市之一，其潮汐现象尤为典型。本文基于摩拜单车 2016 年 8 月的上海全量订单数据，从随机过程的视角对潮汐现象进行建模与优化，旨在为共享单车系统的调度决策提供理论支撑。

1.2 文献综述

共享单车系统的调度优化问题已有丰富的研究积累，主要可分为以下三个方向：

(1) 时间序列预测方法。传统研究多采用 ARIMA、LSTM 等时间序列模型预测单车需求 [?]。这类方法擅长捕捉需求的周期性规律，但存在根本性局限：时间序列模型预测的是“需求量”而非“系统状态”，无法刻画系统的**状态依赖性**——即当前车辆数量直接影响下一时刻的借还车概率。例如，当停放点车辆数为 0 时，无论需求预测多么准确，借车事件都不可能发生。这种状态依赖性正是排队论与生灭过程的核心优势所在。

(2) 马尔可夫决策过程（MDP）。部分研究将单车系统建模为 MDP，通过动态规划求解最优调度策略 [?]。然而，MDP 方法面临“维度诅咒”：当系统包含 M 个站点时，状态空间大小为 $(K+1)^M$ ，即使仅有 10 个站点、容量 15，状态空间已达 $16^{10} \approx 10^{12}$ ，计算上不可行。此外，MDP 通常假设转移概率已知且时不变，与潮汐场景下的时变特性矛盾。

(3) 排队论与生灭过程。将单个停放点建模为排队系统是最自然的框架 [?][?]。早期研究多采用齐次 $M/M/1/K$ 模型，假设到达率与离开率为常数。然而，单车系统的到达率随时间剧烈变化（早高峰 $\lambda \approx 50/\text{hr}$ vs 深夜 $\lambda \approx 1/\text{hr}$ ），齐次假设严重偏离现实。Fricker & Gast[?] 研究了齐次模型下的稳态分布，但明确指出潮汐现象下稳态解不适用。

在国内研究中，李军和朱从坤 [?] 利用排队论模型研究了公共自行车站点车辆调度数的确定方法，指出站点容量与调度策略的协同优化是提升系统效率的关键。高亮等 [?] 提出基于预测库存变化率的公共自行车动态调度方法，其“动态调度”和“库存变化率”的概念与本文动态阈值策略在理念上高度一致。徐国勋等 [?] 从运筹学角度构建了带时间窗的多类型公共自行车调运车辆路径规划模型，聚焦于最小化运输成本；然而当单次调度成本极大时，单纯的路线优化已无法弥补高频调度的亏损——这正是本文将研究视角从“路径优化”转向“是否应该调度”的核心动机。

本文的创新点在于：

1. 采用非齐次生灭过程 (Non-homogeneous Birth-Death Process, NHBD) $M(t)/M(t)/1/K$

模型，允许到达率 $\lambda(t)$ 和离开率 $\mu(t)$ 随时间变化，更真实地反映潮汐特征；

2. 在方法论层面，对数据时间精度进行严格诊断，发现分钟级离散化问题后，转而采用小时级计数泊松检验（VMR 分散检验）替代传统的到达间隔 K-S 检验，并从理论上论证了“过分散恰恰是 NHPP 核心特征而非其反面”的结论；
3. 对两个互补的潮汐站点（净流入站 CBD 与净流出站 RES）同时建模，通过对比分析揭示了潮汐现象在空间上的镜像对称性；
4. 利用 Kolmogorov 前向方程的数值求解获得瞬态概率分布 $P(N(t) = n)$ ，而非仅依赖稳态解——这是潮汐场景下唯一正确的分析方法；
5. 基于 Gillespie 算法进行大规模随机仿真（200 条轨迹），验证 ODE 数值解的正确性；
6. 提出动态 $(s(t), S(t))$ 调度阈值策略，并通过双站点对比实验得出核心洞察：卡车调度的边际收益极低，从而论证扩容与逆向补贴作为更优替代方案的经济合理性。

2 上海市单车数据的时空 EDA 与热点挖掘

2.1 数据来源与清洗

本文使用的数据为 2016 年 8 月摩拜单车上海开源数据集 (Mobike Shanghai Dataset) [?], 该数据集在学术界被广泛使用 [?], 包含 102,361 条订单记录。每条记录包含以下字段：订单编号 (orderid)、单车编号 (bikeid)、用户编号 (userid)、借车时间与还车时间 (start_time / end_time)、起点与终点的经纬度坐标 (start_location_x/y, end_location_x/y)。

数据清洗步骤如下：

1. **坐标过滤**：剔除经纬度超出上海合理范围（经度 120.8° – 122.0° E，纬度 30.6° – 31.9° N）的异常记录，共移除 4 条；
2. **时间解析**：将字符串格式的时间字段转换为 MATLAB datetime 对象，提取小时与日期信息。数据覆盖 2016 年 8 月 1 日至 8 月 31 日共 31 天，其中工作日 23 天、周末 8 天；
3. **坐标转换**：将经纬度转换为以上海中心 (121.47° E, 31.23° N) 为原点的米制坐标，转换因子为：1 度纬度 ≈ 111 km, 1 度经度 $\approx \cos(31.23^{\circ}) \times 111 \approx 95.0$ km。此转换确保 K-Means 聚类中距离计算的物理合理性。

清洗后保留 102,357 条有效记录。值得注意的是，本文在后续分析中仅使用工作日数据（23 天），以避免周末出行模式与工作日的系统性差异对统计推断造成干扰。

2.2 K-Means 空间聚类与潮汐站点识别

上海市面积超过 6,000 km²，不能将整个城市作为排队论的分析单元。本文采用 K-Means 算法对全天所有借还车位置（起点 + 终点合并，共 204,714 个坐标点）进行空间聚类，设定聚类数 $K = 10$ 。聚类数通过肘部法则（Elbow Method）确定，在聚类紧凑度与区域粒度之间取得平衡。

通过将聚类中心经纬度代入高德地图拾取坐标系统，可识别出各聚类对应的真实地理区域，如表1所示。

表 1: K-Means 统一聚类中心经纬度与地理识别

聚类编号	经度 (°E)	纬度 (°N)	地理识别
1	121.3565	31.1875	闵行区（住宅区）
2	121.4301	31.3269	杨浦区（高校区）
3	121.4778	31.2705	静安寺 CBD（早高峰净流入站）
4	121.5396	31.2738	浦东新区（商务区）
5	121.4161	31.1428	徐汇区南
6	121.4538	31.2086	徐汇区（住宅区）
7	121.3375	31.2639	长宁区西
8	121.5085	31.3175	虹口区
9	121.5321	31.1811	浦东南
10	121.4105	31.2594	中山公园（早高峰净流出站）

2.3 潮汐现象的量化与双站点验证

为识别潮汐站点，本文计算每个聚类区域在早高峰（7:00–9:00）的净流量：

$$\text{NetFlow}_c = \sum_{h=7}^9 [\text{Inflow}_c(h) - \text{Outflow}_c(h)] \quad (1)$$

其中 $\text{Inflow}_c(h)$ 为还车到区域 c 的订单数， $\text{Outflow}_c(h)$ 为从区域 c 借车的订单数。

识别结果：

- **早高峰净流入最大站（CBD）：** Cluster 3 (121.4778°E, 31.2705°N)，对应上海市静安寺/南京西路 CBD 区域。早高峰净流入 +152——大量通勤者骑行至此换乘地铁或到达办公地点。
- **早高峰净流出最大站（RES）：** Cluster 10 (121.4105°E, 31.2594°N)，对应上海市长宁区/中山公园附近的大型住宅区。早高峰净流出 -215——大量居民从此处借车出发。

图??展示了两个潮汐站点 24 小时净流量的变化曲线。两者呈现出令人瞩目的**镜像对称**特征：CBD 站在早高峰呈现显著净流入（车辆涌入），晚高峰呈现净流出；RES 站则完全相反。这一双站点验证为 NHBD 建模提供了坚实的经验基础——我们不仅需要 一个站点，更需要两个互补的站点来完整刻画潮汐现象的全貌。




图 1: 双站点 24 小时净流量变化：净流入站（CBD, Cluster 3）与净流出站（RES, Cluster 10）呈现镜像对称

本文后续将以这两个互补的潮汐站点（Cluster 3 与 Cluster 10）为平行研究对象，分别构建排队论模型。选择双站点的原因是：（1）CBD 与 RES 的潮汐特征互补，单独分析任一站都无法完整刻画系统行为；（2）双站点对比为后续调度优化提供了自然的实验设计——对净流入站与净流出站分别评估调度策略的效果；（3）双站点分析使得” 镜像对称” 的潮汐特征得以量化验证。

3 统计推断与非齐次泊松过程检验

3.1 到达率与离开率的动态切片

将一天切分为 24 个小时块，仅使用工作日数据（ $D = 23$ 天），分别对 CBD 和 RES 两个站点计算每小时的平均借车到达率 $\lambda(t)$ 和还车离开率 $\mu(t)$ ：

$$\lambda(h) = \frac{1}{D} \sum_{d=1}^D N_{\text{borrow}}(h, d), \quad \mu(h) = \frac{1}{D} \sum_{d=1}^D N_{\text{return}}(h, d) \quad (2)$$

图??展示了两个站点 $\lambda(t)$ 和 $\mu(t)$ 的 24 小时变化曲线。关键特征总结如下：
CBD 站（净流入站）：

- 早高峰（8:00）： $\lambda(8) = 51.5/\text{hr}$ ， $\mu(8) = 55.3/\text{hr}$ ，净流入 $+3.8/\text{hr}$ ——还车供给超过借车需求；
- 晚高峰（18:00）： $\lambda(18) = 50.4/\text{hr}$ ， $\mu(18) = 47.9/\text{hr}$ ，净流出 $-2.5/\text{hr}$ ——下班人群从此处借车回家；
- 净流入峰值出现在 9:00（ $\mu - \lambda$ 最大），净流出峰值出现在 17:00（ $\lambda - \mu$ 最大）。

RES 站（净流出站）：

- 早高峰（8:00）： $\lambda(8) = 41.0/\text{hr}$ ， $\mu(8) = 38.3/\text{hr}$ ，净流出 $-2.7/\text{hr}$ ——居民借车出发；
- 晚高峰（18:00）： $\lambda(18) = 39.4/\text{hr}$ ， $\mu(18) = 43.0/\text{hr}$ ，净流入 $+3.7/\text{hr}$ ——居民骑行回家；
- 净流出峰值出现在 7:00，净流入峰值出现在 18:00——与 CBD 站约 1-2 小时的相位差，反映了通勤时间。




图 2: 双站点 24 小时到达率 $\lambda(t)$ 与离开率 $\mu(t)$ 对比：CBD 站（上）与 RES 站（下）的 λ 与 μ 相对大小关系恰好相反

两个站点 $\lambda(t)$ 与 $\mu(t)$ 相对大小关系的颠倒，是潮汐现象最直接的定量证据。更重要的是， $\lambda(t)$ 和 $\mu(t)$ 在一天内的变化范围极大（从深夜的 $< 1/\text{hr}$ 到高峰的 $> 50/\text{hr}$ ），这否定了齐次假设的合理性，确认了采用 NHPP 建模的必要性。

3.2 数据时间精度诊断

在对借还车事件进行泊松过程检验之前，本文首先对数据的时间精度进行了严格诊断。提取 Cluster 3 在早高峰（8:00–9:00）的所有借车事件（35 个），计算到达间隔（inter-arrival times）。诊断结果如下：

- 35 个事件仅产生 26 个唯一时间戳，**重复率 25.7%**——同一分钟内有多于一个借车事件被记录为相同时间；
- 34 个到达间隔中，9 个为零间隔（< 1 秒），11 个小于 60 秒，**中位数为 60.0 秒**；
- **82% 的到达间隔为 60 秒的整数倍**（60s, 120s, 180s, 240s, 300s 等）。

这一结果明确表明：原始数据的时间字段**仅具有分钟级精度**，而非标注的“秒级精度”。时间戳被截断至最近的整分钟值，导致到达间隔呈现离散化特征。

注 1. 分钟级离散化对到达间隔的 $K-S$ 检验具有致命影响： $K-S$ 检验要求连续分布，而离散化数据在 CDF 的跳跃点处产生大量同值观测，使得 $K-S$ 统计量 D 被严重放大，几乎必然拒绝连续分布的原假设。因此，到达间隔的 $K-S$ 检验在本数据集上不适用，不应作为泊松过程检验的方法。

3.3 小时级计数泊松检验

鉴于到达间隔检验不适用，本文转而采用小时级计数检验——这是 NHPP 定义的核心层面。非齐次泊松过程的定义要求：在时段 $[t_1, t_2]$ 内的事件数 $N(t_1, t_2) \sim \text{Poisson}(\int_{t_1}^{t_2} \lambda(s)ds)$ 。因此，检验每小时的事件数是否服从泊松分布，是验证 NHPP 假设的直接且合理的方法。

3.3.1 方差-均值比（VMR）分散检验

对于泊松分布，方差等于均值（ $\text{Var} = \text{Mean}$ ），即方差-均值比（VMR）应为 1。VMR 显著大于 1 表明**过分散**（over-dispersion），即数据比泊松分布更分散。

对两个站点的 6 个高峰时段（7:00, 8:00, 9:00, 17:00, 18:00, 19:00），分别收集 23 个工作日的每日借车数与还车数，计算 VMR 并进行 χ^2 分散检验：

$$\text{VMR}_h = \frac{\text{Var}(N_h)}{\text{Mean}(N_h)}, \quad \chi_h^2 = (D-1) \cdot \text{VMR}_h, \quad p_h = 1 - F_{\chi^2}(\chi_h^2, D-1) \quad (3)$$

其中 $D = 23$ 为工作日天数。原假设 H_0 : $\text{VMR} = 1$ （泊松分布）；备择假设 H_1 : $\text{VMR} > 1$ （过分散）。

检验结果如表??和图??所示。两个站点所有高峰时段的 **VMR 均显著大于 1**（CBD 范围 3.42–10.13，RES 范围 3.18–8.87）， χ^2 分散检验的 p 值均近似为 0，在 5% 水平下**拒绝了泊松分布假设**。

表 2: 双站点小时级计数泊松分散检验结果（工作日， $D = 23$ ）

时段	CBD（借车/还车）		RES（借车/还车）		泊松基准
	VMR _借	VMR _还	VMR _借	VMR _还	
7:00	5.18	4.44	4.92	4.15	1
8:00	6.60	7.67	5.83	5.46	1
9:00	4.45	5.36	4.21	5.12	1
17:00	3.42	3.61	3.18	3.93	1
18:00	10.13	8.68	8.87	7.74	1
19:00	5.20	5.90	4.78	5.31	1




图 3: 双站点各高峰时段 VMR 值：CBD 与 RES 所有时段均远超 1（泊松基准线），且两站 VMR 模式高度一致

3.4 过分散的深层分析：从拒绝到确认

表面上看，拒绝泊松分布假设似乎否定了 NHPP 建模的合理性。然而，本文通过深入分析，论证了过分散恰恰是 **NHPP** 的核心特征，而非其反面。

跨日 VMR 过分散的来源可分解为两个组分：

$$\text{Var}(N_h) = \underbrace{E[\text{Var}(N_h | \lambda_h^{(d)})]}_{\text{泊松变异}} + \underbrace{\text{Var}(E[N_h | \lambda_h^{(d)}])}_{\text{日间异质性}} \quad (4)$$

其中 $\lambda_h^{(d)}$ 为第 d 天时段 h 的真实到达率。第一项为泊松变异（若每天 λ_h 相同，等号成立）；第二项为日间异质性——不同天的 λ_h 不同（受天气、节假日、随机波动影响）导致的额外方差。

本文的核心论证逻辑如下：

1. 若借还车过程为**齐次泊松过程**（HPP， λ 为常数），则跨日 VMR 应接近 1；
2. 观测 $\text{VMR} = 3.42\text{--}10.13$ （CBD）与 $3.18\text{--}8.87$ （RES），远大于 1，**拒绝 HPP**；
3. NHPP 允许 $\lambda(t)$ 随时间变化，不同天的 $\lambda(t)$ 轨迹存在差异，导致跨日计数过分散；
4. 因此，**拒绝 HPP 恰恰确认了 NHPP 的必要性**——只有允许 $\lambda(t)$ 随时间变化，才能解释观测到的过分散。

进一步地，CBD 站高峰时段 $\lambda(t)$ 的跨小时变异： $\text{Var}(\lambda_h) = 130.1$ （6 个高峰时段之间），而 $\text{Mean}(\lambda_h) = 42.65$ 。若 λ 为常数，期望 VMR 为 1； λ 的剧烈跨小时变异使得合并多时段数据后的 VMR 必然远大于 1。双站点分析为这一逻辑提供了更强的佐证——两个站点的 VMR 模式高度一致（如图??所示），表明过分散是系统性的而非站点特异的。

3.5 非齐次泊松过程的建立

综合以上分析，本文将全天借还车过程定义为**非齐次泊松过程**（NHPP），其到达率 $\lambda(t)$ 为时间的分段常数函数：

$$\lambda(t) = \lambda_h, \quad t \in [h, h+1), \quad h = 0, 1, \dots, 23 \quad (5)$$

同理，还车过程亦为 NHPP，到达率 $\mu(t)$ 按相同方式定义。

这一建模决策的学术合理性基于以下三点：

1. **理论层面**：NHPP 的核心是 $\lambda(t)$ 变时变，而非到达间隔严格服从指数分布。小时级计数检验拒绝了 HPP，确认了 $\lambda(t)$ 的非齐次性——这正是 NHPP 的定义性特征；
2. **实证层面**：分段常数 NHPP 在 Gillespie 仿真中表现良好，仿真结果与 ODE 数值解高度吻合（见第 4 章），验证了模型的有效性；
3. **方法层面**：分钟级离散化是数据采集的局限而非模型的错误。通过转而采用小时级计数检验，本文在方法论层面规避了这一局限。

4 基于 $M(t)/M(t)/1/K$ 变参数生灭过程的理论建模

4.1 模型构建

将单个停放点建模为容量为 K 的生灭过程。状态 $N(t)$ 表示时刻 t 停放点的单车数量，状态空间为 $\{0, 1, 2, \dots, K\}$ 。两个站点分别配置不同的容量：CBD 站 $K = 50$ （地铁站出口区域，停车空间相对紧凑），RES 站 $K = 80$ （住宅区有更充裕的停车空间）。

状态转移规则如下：

- 还车事件 (birth): $N(t) \rightarrow N(t) + 1$, 转移率 $\mu(t)$ (当 $N(t) < K$ 时有效);
- 借车事件 (death): $N(t) \rightarrow N(t) - 1$, 转移率 $\lambda(t)$ (当 $N(t) > 0$ 时有效);
- 边界条件: $N(t) = 0$ 时只能还车 (空站无法借车), $N(t) = K$ 时只能借车 (满站无法还车)。

注 2. 本文的 "birth"/"death" 术语与排队论中 "arrival"/"departure" 的对应关系为: birth (生) = 还车使单车数量增加 = 排队论中的到达; death (灭) = 借车使单车数量减少 = 排队论中的离开。这一命名与单车系统的物理直觉一致。

状态转移图如图??所示。




图 4: $M(t)/M(t)/1/K$ 生灭过程状态转移图

4.2 Kolmogorov 前向方程

令 $P_n(t) = \Pr(N(t) = n)$ 为时刻 t 状态为 n 的概率。定义概率向量 $\mathbf{P}(t) = [P_0(t), P_1(t), \dots, P_K(t)]$, 则 Kolmogorov 前向方程为:

$$\frac{d\mathbf{P}(t)}{dt} = \mathbf{P}(t) \cdot \mathbf{Q}(t) \quad (6)$$

其中 $\mathbf{Q}(t)$ 为时变转移速率矩阵 (Q 矩阵), 其结构为:

$$\mathbf{Q}(t) = \begin{pmatrix} -\mu(t) & \mu(t) & 0 & \cdots & 0 \\ \lambda(t) & -(\lambda(t) + \mu(t)) & \mu(t) & \cdots & 0 \\ 0 & \lambda(t) & -(\lambda(t) + \mu(t)) & \cdots & 0 \\ \vdots & & & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda(t) & -\lambda(t) \end{pmatrix} \quad (7)$$

具体地, 各状态的概率演化方程为:

$$\frac{dP_0(t)}{dt} = -\mu(t)P_0(t) + \lambda(t)P_1(t) \quad (8)$$

$$\frac{dP_n(t)}{dt} = \mu(t)P_{n-1}(t) - (\lambda(t) + \mu(t))P_n(t) + \lambda(t)P_{n+1}(t), \quad 1 \leq n \leq K-1 \quad (9)$$

$$\frac{dP_K(t)}{dt} = \mu(t)P_{K-1}(t) - \lambda(t)P_K(t) \quad (10)$$

4.3 瞬态解的数值方法

关键问题：由于 $\lambda(t)$ 和 $\mu(t)$ 随时间剧烈变化，传统的稳态分布（Stationary Distribution）不再适用。稳态分布要求 λ 和 μ 为常数，且系统已运行足够长时间达到平衡——这在潮汐场景下完全不成立。例如，早高峰 $\lambda(t)$ 在 2 小时内从约 10/hr 飙升至 51/hr，系统根本无法达到任何“稳态”。因此，本文必须求解瞬态概率分布。

本文采用前向欧拉法对方程 (??) 进行数值求解：

$$\mathbf{P}(t + \Delta t) = \mathbf{P}(t) + \mathbf{P}(t) \cdot \mathbf{Q}(t) \cdot \Delta t \quad (11)$$

时间步长 $\Delta t = 0.001$ 小时（3.6 秒），共 24,000 步覆盖 24 小时。每步后对概率向量进行非负修正与归一化：

$$P_n(t + \Delta t) = \max(P_n(t + \Delta t), 0), \quad \sum_{n=0}^K P_n(t + \Delta t) = 1 \quad (12)$$

注 3. 为确保数值稳定性，本文选择 $\Delta t = 0.001$ 小时（3.6 秒），使得 $\max_t \|\mathbf{Q}(t)\| \cdot \Delta t < 0.3$ 。前向欧拉法对生灭过程的数值求解要求步长足够小以保证概率守恒（ $\sum_n P_n = 1$ ）与非负性（ $P_n \geq 0$ ），3.6 秒的时间步长在早高峰 $\lambda(t) \approx 50/hr$ 的条件下确保单步转移概率远小于 1，满足数值稳定性条件。

初始条件设定为凌晨 0 点的确定性分布： $P_{N_0}(0) = 1$ ，其中 CBD 站 $N_0 = 25$ （容量的一半），RES 站 $N_0 = 40$ （容量的一半）。这一选择反映了夜间运营准备后的典型初始存量。

5 Gillespie 仿真与经济学动态调度优化

5.1 Gillespie 算法仿真

Gillespie 算法 [?] (Stochastic Simulation Algorithm, SSA) 是连续时间马尔可夫过程的标准仿真方法。本文基于第 3 章估计的真实 $\lambda(t)$ 和 $\mu(t)$ ，对两个站点的 $M(t)/M(t)/1/K$ 模型分别进行 200 次 Monte Carlo 仿真。

算法流程如下：

Algorithm 1 Gillespie 算法仿真 $M(t)/M(t)/1/K$

```
1: 初始化:  $t = 0, N = N_0$ 
2: while  $t < T$  do
3:   计算当前时段的  $\lambda(t)$  和  $\mu(t)$  (分段常数)
4:   计算有效事件率:  $a_{\text{birth}} = \mu(t) \cdot \mathbf{1}_{N < K}, a_{\text{death}} = \lambda(t) \cdot \mathbf{1}_{N > 0}$ 
5:    $a_0 = a_{\text{birth}} + a_{\text{death}}$ 
6:   if  $a_0 = 0$  then
7:      $t \leftarrow t + \Delta t_{\text{min}}$ , 继续
8:   end if
9:   生成下一事件时间:  $\Delta t = -\ln(r_1)/a_0$ , 其中  $r_1 \sim U(0, 1)$ 
10:   $t \leftarrow t + \Delta t$ 
11:  决定事件类型: 若  $r_2 < a_{\text{birth}}/a_0$ , 则  $N \leftarrow N + 1$  (还车); 否则  $N \leftarrow N - 1$  (借车)
12: end while
```

仿真参数: CBD 站 $K = 50, N_0 = 25$; RES 站 $K = 80, N_0 = 40$; $T = 24$ 小时, 仿真次数 $n_{\text{sim}} = 200$ 。时间步长 $\Delta t_{\text{sample}} = 1/5760$ 天 (15 秒), 每天共 5,761 个观测点。

5.2 ODE 数值解与 Gillespie 仿真对比

图??展示了两个站点的 ODE 期望值 $E[N(t)]$ 与 Gillespie 仿真均值轨迹的对比。两者高度吻合, 验证了数值求解与仿真实现的双向正确性。

关键观测:

- CBD 站全天 $E[N(t)]$ 在 21–28 之间波动, 相对 $K = 50$ 的容量处于中间偏低区域, 与净流入站在早高峰的车辆堆积特征一致;
- RES 站全天 $E[N(t)]$ 在 38–42 之间波动, 相对 $K = 80$ 的容量处于中间区域, 净流出在早高峰显著但 $K = 80$ 提供了充足缓冲;
- 两个站点 ODE 解与 Gillespie 仿真的高度吻合 (曲线几乎重叠) 表明: 200 条样本路径足以获得稳定的期望估计。




图 5: 双站点 ODE 数值解 vs Gillespie 仿真: 期望单车数量对比 (CBD $K = 50$, RES $K = 80$)

图??进一步展示了双站点的 Gillespie 仿真样本路径 (50 条), 清晰呈现了随机过程的样本路径变异性。




图 6: 双站点 Gillespie 仿真样本路径 (50 条): CBD 站 (上) 车辆在 20–30 之间波动, RES 站 (下) 在 35–45 之间波动

5.3 瞬态概率分布与风险评估

图??展示了两个站点 $P(N(t) = n)$ 随时间变化的瞬态概率分布热力图。热力图的横轴为 24 小时时间线, 纵轴为状态 n (从 0 到 K), 颜色深度表示该时刻系统处于状态 n 的概率大小。从视觉上看, CBD 站的热力图呈现明显的**双翼扩散模式**: 概率质量从凌晨的确定性起点 $N_0 = 25$ 向外扩散, 在早高峰时段 (7:00–9:00) 概率分布显著展宽——同时向低状态 (空站风险) 和高状态 (满站风险) 两个方向延伸, 形成”沙漏型”结构。

这种双向扩散是 $\lambda(t) \approx \mu(t)$ 且两者均处于高位的自然结果：大量借还车事件同时发生，系统在边界之间频繁摆动，概率质量被推向两端。

相比之下，RES 站的热力图呈**单侧偏移**模式：概率质量主要向低状态方向偏移（受早高峰净流出驱动），而高状态端始终保持紧凑。这是由于 RES 站 $K = 80$ 的大容量使上界吸收了大部分扩散能量——即使还车率短暂超过借车率，充足的上行空间也阻止了概率质量在满站边界积累。

从 ODE 数值解中提取的关键时段风险概率如表??所示。

表 3: 双站点关键时段空站与满站概率

站点	时段	$E[N(t)]$	$P(N(t) = 0)$	$P(N(t) = K)$
CBD ($K = 50$)	0:00	25.00	0.0000	0.0000
	8:00	21.93	10.80%	10.17%
	18:00	21.35	5.28%	3.32%
	23:00	24.23	3.61%	3.44%
RES ($K = 80$)	0:00	40.00	0.0000	0.0000
	8:00	38.12	4.32%	1.35%
	18:00	39.24	3.17%	0.82%
	23:00	40.18	2.89%	1.07%




图 7: 双站点瞬态概率分布 $P(N(t) = n)$ 热力图：CBD 站（上）与 RES 站（下）

关键发现：

- CBD 站早高峰 8:00 空站概率高达 **10.80%**，满站概率 **10.17%**——约每 10 天出现一次早高峰空站或满站事件，说明 CBD 站的潮汐压力集中在早高峰；

- RES 站早高峰 8:00 空站概率 **4.32%**——显著低于 CBD 站，得益于 $K = 80$ 的较大容量缓冲；满站概率仅 1.35%；
- 满站概率呈现有趣的站点差异：CBD 站满站概率（10.17%）显著高于 RES 站（1.35%）——CBD 在早高峰集中还车是满站的主因；
- 从 Gillespie 仿真统计得到的空站/满站比例与 ODE 概率高度一致，验证了瞬态概率分布求解的准确性。

图??展示了两个站点的空站与满站风险概率的 24 小时时序变化。CBD 站的风险模式呈现显著的**单峰尖峰**结构：空站概率与满站概率在 8:00–9:00 同时达到峰值（各约 10%），这意味着 CBD 站早高峰不仅面临借车需求枯竭的风险，也同时面临还车需求溢出的压力——两种风险同时存在且幅度相当，是 CBD 站”双向受压”特征的直接体现。相比之下，RES 站的风险曲线更加平稳：空站风险在 7:00–9:00 维持在 3%–4% 的水平，满站风险始终低于 2%。这一差异源于 RES 站 $K = 80$ 的大容量提供了充分的缓冲，使风险分散至更宽的时段区间而非集中爆发。

此外，两站的晚高峰风险均显著低于早高峰：CBD 站 18:00 空站概率降至 5.28%（早高峰为 10.80%），RES 站同期仅 3.17%。这一不对称性说明早高峰的跨站点净流量规模大于晚高峰——上海市通勤出行在早晨更加集中和单向化。




图 8: 双站点空站与满站风险概率 24 小时时序：CBD 高峰空站风险集中在 8:00–9:00，RES 风险分布更均匀

5.4 经济学动态调度优化

5.4.1 成本函数

建立带惩罚项的经济学成本函数：

$$\min_{s(t), S(t)} E \left[\int_0^T (C_{\text{lost}} \cdot \mathbf{1}_{\{N(t)=0\}} + C_{\text{penalty}} \cdot \mathbf{1}_{\{N(t)=K\}}) dt \right] + \sum_{\text{dispatch events}} C_{\text{dispatch}} \quad (13)$$

其中：

- $C_{\text{lost}} = 2$ ：空站损失成本（每次借车请求失败造成的用户流失损失）；
- $C_{\text{penalty}} = 1$ ：满站惩罚成本（每次还车请求失败造成的运维压力）；
- $C_{\text{dispatch}} = 50$ ：调度成本（卡车运输的人力与物流成本）。

成本参数的设定体现了明确的商业逻辑：空站损失大于满站惩罚（ $C_{\text{lost}} > C_{\text{penalty}}$ ），而调度成本远大于两者之和（ $C_{\text{dispatch}} \gg C_{\text{lost}} + C_{\text{penalty}}$ ）。这意味着调度干预仅在空站/满站概率累积到足够高时才经济合理——微小的概率波动不值得调度成本。

5.4.2 动态 $(s(t), S(t))$ 阈值策略

由于 $\lambda(t)$ 和 $\mu(t)$ 随时间剧烈变化，调度触发阈值也应为时间的函数。本文提出动态阈值策略：

- 调入阈值 $s(t)$ ：当 $N(t) < s(t)$ 时触发调入，将车辆补充至目标值；
- 调出阈值 $S(t)$ ：当 $N(t) > S(t)$ 时触发调出，将多余车辆移走。

阈值的确定基于瞬态概率分布——当期望损失超过调度成本时触发干预：

$$s(t) : \Pr(N(t) < s) \cdot C_{\text{lost}} > C_{\text{dispatch}} \quad (14)$$

$$S(t) : \Pr(N(t) > S) \cdot C_{\text{penalty}} > C_{\text{dispatch}} \quad (15)$$

5.4.3 双站点调度优化结果

基于 200 条 Gillespie 仿真轨迹，分别对两个站点评估动态调度策略的效果。核心结果汇总于表??和图??。

表 4: 双站点调度优化结果（200 条仿真轨迹， $C_{\text{dispatch}} = 50$ ）

场景	无调度日成本	调度后日成本	成本变化
CBD 站 ($K = 50$)	41.20 元	44.92 元	+9.0%
RES 站 ($K = 80$)	8.48 元	5.00 元	-41.0%
双站合计	49.68 元	49.92 元	+0.5%




图 9: 双站点调度成本对比: CBD 站调度使成本上升 9.0%, RES 站节省 41.0%, 全局净效果几乎为零

这一结果蕴含着深刻的经济学洞察:

(1) **CBD 站调度成本反增 9.0% 的深层机制——高频无效抖动 (High-frequency Chattering)**。CBD 站早高峰净流入特征使其面临严重的满站压力 ($P(N = K) = 10.17\%$)。当动态阈值策略检测到满站风险并触发调出操作时, 卡车拉走一批车辆, 站点容量暂时释放。然而 CBD 站 $K = 50$ 的容量相对于高峰时段高达 55.3 辆/hr 的净流入率而言过小——在卡车完成调出后的极短时间内 (约 10–15 分钟), 涌入的还车流再次将站点填满, 阈值 $S(t)$ 被二次触发。系统由此陷入**高频无效抖动死循环**: 调出 → 充满 → 再调出 → 再充满。每次调出花费 50 元固定成本, 但仅挽回约 2 元的满站惩罚收益——调度成本被频繁触发, 如滚雪球般急剧累积, 最终导致 CBD 站的调度后总成本 (44.92 元) 反超无调度基线 (41.20 元)。这一结果从反面雄辩地证明: 当基础设施容量 K 存在严重瓶颈时, 单纯依赖动态阈值调度不仅无效, 反而会恶化系统的经济性——这正是运筹学中“过度控制” (Over-controlling) 的典型症状。

(2) **RES 站调度节省 41.0% 的成功逻辑**。相比之下, RES 站 $K = 80$ 的充裕容量使满站风险极低 (1.35%), 调度的焦点集中于空站风险 (4.32%)。每次调入操作以 50 元成本阻止了约 2–4 元的空站损失——但由于 RES 站净流出后的恢复周期更长 (需要晚高峰还车流才能自然补充), 调度后的车辆存量可维持较长时间, 不会陷入如 CBD 站那样的高频震荡。因此 RES 站的调度是**低频、高价值的精准干预**: 击中要害、一次到位、循环可控。

(3) 全局净效果近乎为零 (+0.5%) 的理性决策含义。CBD 站的额外成本几乎完全抵消了 RES 站的节省。这意味着，在 $C_{\text{dispatch}} = 50$ 元的假设下，通过卡车进行密集调度在全局层面上几乎不产生净收益。更重要的是，这一结果暗示：**一个理性的运筹学决策者应当对 CBD 站采取”不干预 (Do Nothing)”策略**——既然 CBD 调度亏损 9%，最优策略就是只对 RES 站调度（节省 41%），CBD 保持自然运行（成本不变 0%），则全局净节省可达约 17%。这一洞察使调度策略从”全站点统一调度”进化为”选择性精准调度”。




图 10: 动态调度阈值与小时成本率：高风险时段触发调度干预，但 CBD 站的高频调度循环导致成本反增

5.5 讨论：卡车调度 vs 扩容 vs 逆向补贴

调度优化的核心结果——全局净节省仅 0.5%——并非模型的失败，而是**重要的经验证据**。它表明：在 $C_{\text{dispatch}} \gg C_{\text{lost}}$ 的现实约束下，传统卡车调度的经济可行性存在根本性限制。

本节将调度策略与两种替代方案进行定量对比：

方案一：扩大基础设施容量 K （画线扩容）。将 CBD 站点容量从 $K = 50$ 扩展至 $K = 60$ ，直接降低空站/满站概率，无需任何运营干预。本文的 ODE 模型可直接评估

不同 K 值下的风险概率。如表??所示，容量从 50 增至 60 使 CBD 站每日期望损失从 41.20 元降至约 32.50 元，节省幅度约 21%——显著优于调度策略的 -9.0%。

表 5: 容量 K 对 CBD 站点期望损失的影响（无调度场景）

K	$P(N = 0)$ 峰值	$P(N = K)$ 峰值
40	8.59%	7.87%
50	10.80%	10.17%
60	4.89%	3.32%
80	2.81%	2.08%

方案二：逆向红包补贴（需求侧管理）。徐国勋等 [?] 探讨了基于” 红包车” 机制的需求侧管理策略，证明价格激励可以诱导用户自发完成车辆再分配。本文在此基础上进一步量化了补贴的经济学边界。通过对从高风险区域借车的用户提供红包补贴，驱动用户自发完成调度——将” 重资产物理调度” 转化为” 轻资产用户行为调度”。逆向补贴的经济学理论基础在于**边际成本替代**：卡车调度一次花费 50 元，单次可调拨约 20 辆车，折合每辆车的物理调度成本为 $50 \div 20 = 2.5$ 元。因此，只要平台对用户的逆向红包补贴低于 2.5 元/次（例如设定为 1-2 元），利用价格歧视引导用户自发骑行调度的经济效率就**严格优于**卡车物理调度。即便考虑到单次骑行的直接收益仅约 1 元、每用户流失的长远商业损失约为 4 元（ $C_{\text{lost}} = 2 \text{ 元} \times 2 \text{ 倍用户生命周期价值}$ ），逆向补贴 2 元的期望净成本仍不超过 $2 - 4 \times \text{Pr}(\text{用户流失增值}) \approx 1$ 元，远低于卡车调度的 2.5 元/辆。这从根本上改变了调度优化的经济账：物理调度边际成本 2.5 元/辆 vs 逆向补贴边际成本 1-2 元/辆，后者具有压倒性的成本优势，且不产生额外的物流与碳排放。

5.6 研究结论的核心启示

在高昂的物理调度成本（ $C_{\text{dispatch}} = 50$ 元/次）面前，通过卡车进行密集调度的边际收益极低。模型结果显示：

- RES 站（住宅区）动态调度节省 41.0%，验证了调度策略在净流出站点上的有效性；
- 但 CBD 站（净流入站）调度反而使成本上升 9.0%，全局净节省仅 0.5%；
- 这一鲜明对比揭示了：在同时存在净流入与净流出的潮汐系统中，卡车调度的净收益被站间调度成本的相互抵消所侵蚀。

这不仅验证了通过扩大基础设施容量 K （画线扩容）或引入逆向红包补贴（将调度成本转嫁给具有时间弹性的用户）相比于传统重资产卡车调度具有**压倒性的经济学优越性**。从政策设计的角度，与其投入资源进行低效的物理调度，不如将资源用于：（1）在

CBD/地铁站出口画设更多停车位（增大 K ）；（2）对从高需求区域逆向骑行的用户提供补贴激励。

6 结论与政策探讨

6.1 主要结论

1. 通过 K-Means 空间聚类，成功从 102,361 条上海摩拜单车订单数据中自动识别出一对互补的潮汐站点：净流入站（Cluster 3，静安寺 CBD）和净流出站（Cluster 10，中山公园住宅区），并量化了两个站点 24 小时净流量近乎镜像对称的潮汐特征。
2. 对数据时间精度进行了严格诊断，发现原始数据仅具有分钟级精度（82% 的到达间隔为 60 秒整数倍）。基于此发现，采用小时级计数泊松检验替代传统的到达间隔 K-S 检验。两个站点所有高峰时段的 VMR 均显著大于 1（CBD: 3.42–10.13, RES: 3.18–8.87），拒绝了齐次泊松过程假设。进一步论证了过分散是 $\lambda(t)$ 变时变的必然结果，拒绝 HPP 恰恰确认了 NHPP 的必要性——这一结论得到了双站点一致性 VMR 模式的有力佐证。
3. 为两个站点分别构建了 $M(t)/M(t)/1/K$ 非齐次生灭过程模型（CBD $K = 50$, RES $K = 80$ ），通过 Kolmogorov 前向方程的数值求解获得了瞬态概率分布。Gillespie 仿真（200 条轨迹）与 ODE 解高度吻合，验证了模型与求解方法的正确性。CBD 站早高峰空站概率 10.80%、满站概率 10.17%；RES 站分别为 4.32% 和 1.35%—— K 值越大，风险越低。
4. 双站点调度优化实验是本文的核心经验贡献。结果表明：RES 站调度节省 41.0%，证明动态阈值策略的有效性；但 CBD 站调度成本上升 9.0%，全局净效果仅 +0.5%。这一发现揭示了一个重要现实：在 $C_{\text{dispatch}} \gg C_{\text{lost}}$ 的高昂调度成本约束下，卡车调度的边际收益极低，尤其在同时存在净流入与净流出站的系统中，调度成本相互抵消。
5. 基于上述发现，本文论证了两种替代方案的经济学优越性：（1）扩大基础设施容量 K （画线扩容）直接降低风险概率且无运营成本，CBD 站容量从 50 增至 60 可使空站/满站概率分别降至 4.89% 和 3.32%；（2）逆向红包补贴将重资产物理调度转化为轻资产用户行为调度——基于边际成本替代原理，卡车调度折合 2.5 元/辆，逆向补贴仅需 1–2 元/次即可实现更优的经济效率，从根本上改变了调度优化的成本结构。

6.2 政策探讨：潮汐现象的博弈属性

潮汐现象本质上是一个**博弈问题**：单车企业的调度成本与用户的出行便利之间存在利益冲突。基于本文的双站点定量分析，建议以下政策方向：

(1) **容量规划科学化**。实证结果表明，增大 K 是降低风险最直接的手段，且边际成本远低于物理调度。建议政府或单车企业在 CBD/地铁站出口画设更多停车位 ($K = 50-60$)，在住宅区配置适中容量 ($K = 80$)，从基础设施层面缓解潮汐压力。

(2) **动态定价（价格歧视）平抑潮汐**。在早高峰对从住宅区借车的用户收取较低费用（鼓励提前借车），对从 CBD 还车的用户提供补贴（缓解区域拥堵）。逆向补贴分析为这一策略提供了经济学可行性边界——系统可承受的最高补贴远高于实际投入。

(3) **信用积分激励替代物理调度**。将”重资产卡车调度”转化为”轻资产用户自发调度”。对将车辆从满站骑行至空站的用户给予信用积分奖励——这一策略在理论上可以将 $C_{\text{dispatch}} = 50$ 元降至接近零，彻底改变调度优化的经济账。

(4) **站点协同与数据驱动决策**。双站点分析表明潮汐系统是一个紧密耦合的网络——单一站点的优化可能以其他站点的恶化为代价。建议采用本文的 ODE 模型对新规划的站点进行事前仿真评估，确定最优容量和调度策略。

6.3 研究局限与展望

- 本文的双站点分析仅覆盖两个最典型的潮汐站点（CBD 与 RES），未考虑多站点之间的耦合关系。实际中，一个站点的借车事件必然对应另一个站点的还车事件，形成网络级联效应。未来可扩展为网络排队模型（Network Queueing Model）。
- $\lambda(t)$ 和 $\mu(t)$ 的分段常数假设较为粗糙（24 段/天）。未来可采用核密度估计或样条函数进行更精细的连续拟合，并引入天气、节假日、降雨量等协变量。
- 调度优化采用启发式阈值策略，未求解全局最优。未来可结合强化学习或 MDP 求解多站点协同最优调度策略。
- 数据仅覆盖 2016 年 8 月，时间精度为分钟级。获取更长时间跨度、秒级精度的数据将显著改善统计推断的可靠性——特别是到达间隔的指数分布拟合。

参考文献

- [1] 高亮, 徐伟. 基于预测库存变化率的公共自行车动态调度方法 [J]. 长安大学学报 (自然科学版), 2019, 39(6): 8.
- [2] 李军, 朱从坤. 基于排队论模型的公共自行车站点车辆调度数研究 [J]. 苏州科技大学学报 (工程技术版), 2019, 32(4): 16-21.

- [3] 徐国勋, 李妍峰, 李军, 徐冠宇. 多类型公共自行车调运问题 [J]. 运筹与管理, 2019, 28(1): 116-124.
- [4] 徐国勋, 李妍峰, 金大祥, 李军. “红包车” 机制下的共享单车调度问题 [J]. 系统工程理论与实践, 2020, 40(2): 426-436.
- [5] Cox D R. Some statistical methods connected with series of events[J]. Journal of the Royal Statistical Society: Series B, 1955, 17(2): 129-164.
- [6] Ester M, Kriegel H P, Sander J, et al. A density-based algorithm for discovering clusters in large spatial databases with noise[C]//KDD'96 Proceedings, 1996: 226-231.
- [7] Fisher R A. On the interpretation of χ^2 from contingency tables, and the calculation of P[J]. Journal of the Royal Statistical Society, 1922, 85(1): 87-94.
- [8] Fricker C, Gast N. Incentives and redistribution in homogeneous bike-sharing systems with stations of capacity[J]. Transportation Science, 2016, 50(3): 509-531.
- [9] Gillespie D T. Exact stochastic simulation of coupled chemical reactions[J]. The Journal of Physical Chemistry, 1977, 81(25): 2340-2361.
- [10] Kleinrock L. Queueing Systems, Volume 1: Theory[M]. New York: Wiley Interscience, 1975.
- [11] Mobike. 2017 Mobike White Paper on Bike-sharing and City Development[R]. Mobike Research Institute, 2018.
- [12] Raviv T, Tzur M, Forma I A. Static repositioning in a bike-sharing system: models and solution approaches[J]. Euro Journal on Transportation and Logistics, 2013, 2(3): 187-229.
- [13] Ross S M. Stochastic Processes[M]. 2nd ed. New York: Wiley, 1996.
- [14] Shu J, Chou M C, Liu Q, et al. Models for effective deployment and redistribution of bicycles within public bicycle-sharing systems[J]. Operations Research, 2013, 61(6): 1346-1359.
- [15] willliu1995. Mobike-Tableau[DS]. GitHub, (2025-04-08) [2026-06-03]. <https://github.com/willliu1995/Mobike-Tableau>.

A 核心代码清单

本文所有代码均基于 MATLAB R2023a 和 Python 3.12 实现，完整代码可访问我的关于该项目的 GitHub 仓库(<https://github.com/xys-sirius/Mobike-Tableau-SP-Project>)。以下列出三个核心模块的关键代码片段。

A.1 附录 A：NHPP 统计推断与双站点 VMR 检验

以下代码选自 `step2_poisson_test.m`，实现了双站点 24 小时到达率 $\lambda(t)$ 与离开率 $\mu(t)$ 的计算、方差-均值比（VMR）分散检验与过分散分析。

```
% 双站点24小时到达率/离开率计算
% CBD站点 (Cluster 3)
lambda_CBD = zeros(24,1); mu_CBD = zeros(24,1);
for h = 0:23
    ac=0; dc=0;
    for i = 1:n_weekdays
        ac = ac + sum((start_cluster==cluster_CBD) & ...
            (data_clean.start_hour==h) & ...
            (data_clean.start_date==weekday_dates(i)));
        dc = dc + sum((end_cluster==cluster_CBD) & ...
            (data_clean.end_hour==h) & ...
            (data_clean.start_date==weekday_dates(i)));
    end
    lambda_CBD(h+1) = ac/n_weekdays;
    mu_CBD(h+1) = dc/n_weekdays;
end
% RES站点 (Cluster 10) 同理计算 lambda_RES, mu_RES

%% 小时级计数泊松检验 (VMR分散检验)
poisson_test_hours = [7, 8, 9, 17, 18, 19]; % Peak hours
for hi = 1:length(poisson_test_hours)
    h = poisson_test_hours(hi);
    daily_counts = zeros(n_weekdays,1);
    for i = 1:n_weekdays
        daily_counts(i) = sum((start_cluster==target) & ...
            (data_clean.start_hour==h) & ...
            (data_clean.start_date==weekday_dates(i)));
    end
end
```

```

end
mean_h = mean(daily_counts); var_h = var(daily_counts);
vmr_h = var_h / mean_h;
chi2_h = (n_weekdays-1) * vmr_h;
p_h = 1 - chi2cdf(chi2_h, n_weekdays-1);
fprintf('Hour %2d: mean=%.2f, VMR=%.4f, p=%.6f\n', ...
        h, mean_h, vmr_h, p_h);
end

```

A.2 附录 B: Gillespie 仿真与 Kolmogorov 前向方程数值解

以下代码选自 `step3_gillespie_sim.m`, 实现了 Gillespie 随机仿真算法与基于三对角 Q 矩阵的 ODE 欧拉法数值求解。

```

%% Gillespie随机仿真算法
K = 50; N0 = 25; T_total = 24; % CBD站配置
n_sim = 200;
for sim = 1:n_sim
    t = 0; N = N0;
    while t < T_total
        hr = floor(t) + 1;
        if hr > 24, hr = 24; end
        lam = lambda_hourly(hr); mu_h = mu_hourly(hr);
        a_birth = mu_h * (N < K);
        a_death = lam * (N > 0);
        a0 = a_birth + a_death;
        if a0 == 0, t = t + 1/60; continue; end
        dt = -log(rand) / a0;
        t = t + dt;
        if rand < a_birth/a0
            N = N + 1; % 还车事件
        else
            N = N - 1; % 借车事件
        end
    end
end

end

%% ODE数值解 (Kolmogorov前向方程 + 前向欧拉法)

```



```

dt_ode = 0.005; % 5ms步长
P = zeros(K+1, n_steps);
P(N0+1, 1) = 1;
for j = 1:n_steps-1
    lam = lam_ode(j); mu = mu_ode(j);
    Pc = P(:,j);
    dP = zeros(K+1, 1);
    dP(1) = -lam*Pc(1) + mu*Pc(2);
    for i = 2:K
        dP(i) = lam*Pc(i-1) - (lam+mu)*Pc(i) + mu*Pc(i+1);
    end
    dP(K+1) = lam*Pc(K) - mu*Pc(K+1);
    Pn = Pc + dP*dt_ode;
    Pn = max(Pn, 0); Pn = Pn / sum(Pn);
    P(:,j+1) = Pn;
end
E_N = (0:K) * P; % 期望单车数量

```

A.3 附录 C：动态 (s, S) 调度阈值优化

以下代码选自 `step4_dispatch_optim.m`，实现了基于网格搜索的静态 (s, S) 策略与动态阈值优化。

```

%% 静态(s,S)网格搜索
S_grid = (10:10:0.9*K)'; % 补货后目标水平
s_grid = (5:5:35)'; % 触发补货阈值
cost_grid = zeros(length(S_grid), length(s_grid));

for i = 1:length(S_grid)
    for j = 1:length(s_grid)
        s_val = s_grid(j); S_val = S_grid(i);
        if s_val >= S_val || S_val > K, continue; end

        daily_cost = 0; daily_dispatch = 0;
        for jt = 1:n_t-1
            hr = floor(t_span(jt)) + 1;
            if hr > 24, hr = 24; end
            lam = lambda_hourly(hr); mu_h = mu_hourly(hr);

```

```

p_dist = P_ode(:, jt); % ODE瞬态概率

% 空站损失 + 满站损失（无调度情况）
loss_rate = lam * p_dist(1) * C_lost + ...
            mu_h * p_dist(K+1) * C_penalty;
daily_cost = daily_cost + loss_rate * dt;

% (s,S)调度触发判断
below_s = sum(p_dist(1:min(s_val+1,K+1)));
if below_s > 0.1 % 触发概率>10%
    daily_dispatch = daily_dispatch + 1;
    daily_cost = daily_cost + C_dispatch;
end
end
cost_grid(i,j) = daily_cost;
end
end
[min_cost, idx] = min(cost_grid(:));
fprintf('最优(s,S)策略: s=%d, S=%d, 日成本=%.2f\n', ...
        s_grid(idx_s), S_grid(idx_S), min_cost);

```